KELOMPOK ⟦ NN⟧ · LAPORAN M1

Laporan M1

Baseline pencarian lintas modal

KELOMPOK	⟦NN⟧ · ⟦nama kelompok⟧	MATA KULIAH	IF25-40304 · Ganjil 2026/2027
DOSEN PENGAMPU	I Wayan Wiprayoga Wisesa	TAHAP	M1 · Pertemuan 11

M0 P10	M1 P11	M2 P12	M3 P13	M4 P14	Klinik P14	Presentasi P15–16

#	Nama	NIM	Peran
1	⟦ *nama lengkap* ⟧	⟦ *NIM* ⟧	1 · Data dan Etika Data
2	⟦ *nama lengkap* ⟧	⟦ *NIM* ⟧	2 · Baseline dan Pipeline
3	⟦ *nama lengkap* ⟧	⟦ *NIM* ⟧	3 · Eksperimen Penyejajaran/Fusi
4	⟦ *nama lengkap* ⟧	⟦ *NIM* ⟧	4 · Evaluasi dan Uji Kasus Sulit
5	⟦ *nama lengkap* ⟧	⟦ *NIM* ⟧	5 · Integrasi dan Koordinasi

1 Ringkasan

Kami membangun pipeline pencarian lintas modal end-to-end pada SEA-VL Indonesia (2.072 gambar train, 275 gambar val) dengan encoder beku: CLIP ViT-B/32 untuk gambar dan teks Inggris, serta `clip-ViT-B-32-multilingual-v1` untuk teks Indonesia, dengan kesamaan kosinus pada vektor ternormalisasi. Pada val (N = 275, seed 0, CPU), R@1 teks Inggris→gambar 38,2% dibanding 19,6% untuk teks Indonesia; gambar→teks 44,7% dibanding 21,5%. **Language gap**: R@1 turun 18,5–23,3 poin (sekitar separuh nilai Inggris), R@10 turun 26–33 poin, dan median rank naik dari 2 menjadi 10. Audit data tidak menemukan gambar kembar byte-identik, tetapi menemukan 12 baris val dengan caption identik dengan train, label kategori berbasis kata kunci yang bising, dan beberapa foto hampir kembar yang membuat R@K menjadi batas bawah.

2 Pipeline

Alur dari data ke peringkat: (1) `train.csv` dan `val.csv` dibaca; (2) gambar dikonversi ke RGB lalu disematkan, sedangkan `caption_id` dan `caption_en` disematkan dengan encoder teks masing-masing; (3) setiap vektor dinormalisasi L2 sehingga hasil kali dalam sama dengan kesamaan kosinus; (4) untuk setiap query, kosinus ke seluruh galeri pada split yang sama dihitung dan diurutkan menurun (galeri val = 275 item), lalu peringkat pasangan aslinya (baris yang sama) dicatat. Seri dihitung secara pesimis. Recall@K adalah porsi query yang pasangannya ada di K teratas. Karena tiap query hanya punya satu item relevan, AP@K = 1/rank bila rank ≤ K dan 0 bila tidak; mAP@K adalah rata-ratanya (K = 10). Tidak ada pelatihan atau penyetelan apa pun, dan `val.csv` hanya dipakai sekali untuk menghitung metrik akhir. Sematan disimpan di `hasil_m1/cache/*.npz` agar M2 tidak mengulang pekerjaan yang mahal.

Komponen	Model / pengaturan
Encoder gambar	sentence-transformers/clip-ViT-B-32 (CLIP ViT-B/32, 512 dimensi, dibekukan)
Encoder teks Indonesia	sentence-transformers/clip-ViT-B-32-multilingual-v1 (DistilBERT multibahasa yang didistilasi ke ruang vektor CLIP, 512 dimensi, dibekukan)
Encoder teks Inggris	sentence-transformers/clip-ViT-B-32 (encoder teks CLIP asli, ruang yang sama dengan gambar)
Batch dan seed	Batch gambar 32, batch teks 64, seed 0. Seed hanya memengaruhi pemilihan contoh query; metrik bersifat deterministik. K untuk mAP = 10.

Tabel 1. Komponen pipeline dan pengaturan. Semua model dibekukan (tanpa pelatihan).

3 Kualitas data

Ukuran dan integritas. 2.347 gambar (train 2.072, val 275). Semua file ada, tidak ada `image_id` ganda, dan tidak ada dua gambar dengan MD5 yang sama. Pemeriksaan hash tidak mendeteksi gambar yang mirip secara visual.

Kategori (label berbasis kata kunci). Ada 11 kategori di train dan 10 di val. `kuliner` dominan: 792 train (38,2%) dan 106 val (38,5%), diikuti `lain-lain` 394 (19,0%) dan `tarian` 243. `alat musik` hanya 4 gambar (0 di val) dan `upacara/ritual` 18 (2 di val), sehingga R@K per kategori tidak stabil. Label bising: martabak manis berlabel `wayang/seni`, bubur ayam `flora/fauna`, bubur ikan teri `tarian`, peron LRT `wayang/seni`, pagoda PIK `tempat/alam`.

Wilayah. Kolom `loc` hanya berisi negara: seluruh 2.347 baris memuat Indonesia, 2.280 (97,1%) hanya Indonesia, dan 67 menyebut negara lain (Malaysia 56, Singapore 38, Thailand 19, Brunei 10). Sebagian subjek memang bukan di Indonesia: Fullerton Hotel Singapura (`sv1_140084068` di train dan `sv1_140084386` di val, situs yang sama di kedua split), MRT Singapura, nasi kandar dan nasi lemak Malaysia, kopi tetes Vietnam. Sebaran provinsi tidak tersedia; hitungan kasar dari kata kunci pada caption: Sumatera ≈160, DKI/Banten ≈128, Jawa Tengah ≈113, Bali ≈107, Jawa Barat ≈102, DIY ≈89, Jawa Timur ≈82, Sulawesi ≈44, Kalimantan ≈21, NTT/Maluku/Papua ≈21; 1.513 caption (64%) tanpa penanda wilayah. Jawa, Sumatera, dan Bali dominan, sedangkan Indonesia timur kurang terwakili.

Duplikat dan leakage. Tidak ada gambar identik. Pada tingkat teks: 50 caption ganda dalam train, 1 dalam val, dan 11 caption val identik dengan caption train (ID dan EN; total 12 baris val). Sebelas baris punya `caption_id` sama dengan `caption_en` (tidak diterjemahkan, mis. “Monumen Pancasila Sakti”). Ada foto yang hampir kembar (Telaga Warna Dieng tiga kali di train; Telomoyo dua kali di val), sehingga target satu-satu menjadi ambigu dan Recall dari kedua bahasa cenderung diremehkan. Kesamaan caption belum membuktikan kebocoran gambar; ini belum diperiksa pada tingkat visual.

Perlu diwaspadai. (a) Sepuluh `caption_id` berbahasa Jawa (label `Javanese`, 3 di val), dan dua baris berlabel Indonesia juga berisi kalimat Jawa (`sv1_140084063`, `sv1_140084064`); encoder teks Indonesia kami dilatih dengan 50+ bahasa yang tidak mencantumkan bahasa Jawa. (b) Artefak terjemahan mesin “51 / 5,000 Porridge…” pada `sv1_140084158`. (c) 22 caption Inggris berpola “a photo of …”, 44 caption Indonesia ≤ 3 kata. (d) 206 baris dengan `caption_fit` < 0,9, 156 dengan `img_quality` < 0,9, dan 21 gambar < 400 px. Catatan: pada `Audit_Dataset_M1.xlsx`, kolom skor tampak rusak oleh format desimal (5,0 menjadi 50; 4,333 menjadi 4333), sedangkan CSV sumber normal (rentang 3,0–5,0); angka audit di atas dihitung ulang dari CSV.

4 Hasil pada split validasi

Semua angka dari eksekusi sendiri pada `val.csv`. Satu baris per arah pencarian.

Arah	R@1	R@5	R@10	mAP@K
gambar → teks ID	0,215	0,375	0,505	0,293
gambar → teks EN	0,447	0,713	0,833	0,559

Arah	R@1	R@5	R@10	mAP@K
teks ID → gambar	0,196	0,418	0,505	0,283
teks EN → gambar	0,382	0,673	0,771	0,507
Selisih ID – EN (gambar → teks)	−0,233	−0,338	−0,327	−0,266
Selisih ID – EN (teks → gambar)	−0,185	−0,255	−0,265	−0,224

Tabel 2. Split val, N = 275 query per arah dengan galeri 275 item, seed 0, CPU; mAP@K dengan K = 10. Median rank: 10 (ID) dan 2 (EN) pada kedua arah.

Query Indonesia kalah dari Inggris pada setiap metrik dan arah. R@1 gambar→teks turun dari 44,7% ke 21,5% (−23,3 poin, −52% relatif) dan teks→gambar dari 38,2% ke 19,6% (−18,5 poin, −49% relatif). Selisih absolut terbesar ada pada R@5 dan R@10 (−25 sampai −34 poin), dan median rank naik dari 2 ke 10. Meski begitu, baseline Indonesia masih jauh di atas acak (R@1 acak = 1/275 = 0,36%; sekitar 54–59 kali lipat). Pada tingkat query, untuk teks→gambar terdapat 60 query yang berhasil di rank 1 dalam Inggris tetapi gagal dalam Indonesia, sedangkan kebalikannya hanya 9; untuk gambar→teks 77 berbanding 13. Per kategori (n kecil, hanya indikatif), `kuliner` (n = 106) paling terdampak: R@1 teks→gambar 4,7% (ID) berbanding 26,4% (EN). Sebagai diagnostik di train (galeri 2.072), R@1 ID/EN adalah 8,9%/21,4% (gambar→teks) dan 6,7%/16,4% (teks→gambar); selisih relatifnya serupa (sekitar 58–59%), tetapi angka mutlaknya jauh lebih rendah, jadi R@K tidak sebanding antar ukuran galeri. Dugaan penyebab (belum diuji, bahan M2): encoder teks Indonesia adalah model siswa hasil distilasi ke teks Inggris CLIP, bukan dilatih bersama gambar, sehingga istilah lokal (bakso, martabak, merek) dan relasi antarkata terpetakan kurang akurat.

5 Sepuluh contoh query Indonesia

Tabel 3. Sepuluh query Indonesia dan tiga hasil teratasnya. Galeri 2.072 gambar train; query diambil acak dari train (seed 0), tanpa seleksi. “Benar?” berarti gambar pasangan di rank 1; “EN” pada catatan adalah rank gambar yang sama bila caption Inggris pasangannya dipakai. Hasil teratas disingkat dari caption gambar yang diambil.

#	Query (ID)	Hasil teratas (3)	Benar?	Catatan
1	Mie Gacoan, mie pedas lengkap dengan Pangsit khas Malang, Jawa Timur	(1) upacara tradisional Bali, dua pria berbaju putih; (2) mie ongklok; (3) gendar pecel	Tidak (rank 73)	GAGAL. Merek “Gacoan” tidak dikenali; top-1 salah domain. EN: rank 3.
2	Kerupuk rasa durian	(1) buah durian; (2) gambar durian; (3) durian musang king	Tidak (rank 13)	GAGAL. Ketiganya buah durian; gambar sebenarnya kemasan kerupuk. EN: rank 1.
3	Pagoda yang terletak di wilayah pecinan Pantai Indah Kapuk (PIK)	(1) Menara Kudus; (2) Klenteng Hok Tjing Rio; (3) Menara Kudus di dekat Masjid Al-Aqsha	Tidak (rank 11)	GAGAL. Jenis bangunan tepat, lokasi tidak bisa ditebak. EN: rank 3.
4	Martabak manis, di dalamnya diolesi mentega, kemudian ditaburi coklat dan kacang tanah	(1) bacem tempe, tahu, telur; (2) tempe goreng; (3) telur balado	Tidak (rank 26)	GAGAL. Martabak tidak dikenali (dianggap lauk). EN: rank 1.
5	Pemandangan dari jembatan penyebrangan orang di depan Bandung Indah Plaza	(1) kemacetan persimpangan Jakarta Barat; (2) alun-alun Magelang; (3) becak menunggu penumpang	Tidak (rank 12)	Bertema jalan/kota, tetapi nama tempat tidak membedakan. EN: rank 10.
6	Persiapan para penari yang akan tampil di karnaval 17 agustus.	(1) penari gedruk buto; (2) delapan penari Ongkek Manis; (3) penari Sang Hanoman	Tidak (rank 107)	Top-3 semuanya penari (konsep benar), tetapi banyak foto penari serupa. EN: rank 48.
7	Becak di tengah kota Garut	(1) becak bersepeda; (2) tempat pesta pernikahan terbuka; (3) delman	Tidak (rank 15)	Top-1 benar secara makna (becak) tetapi bukan pasangannya. EN: rank 13.

#	Query (ID)	Hasil teratas (3)	Benar?	Catatan
8	Para anak-anak yang berperan dalam tarian Wanara sedang melakukan foto bersama.	(1) dua penari Manipuren foto bersama; (2) lomba paku botol; (3) penari restorasi Borobudur foto bersama	Tidak (rank 53)	Menangkap "foto bersama", bukan "Wanara". EN: rank 59 (gagal di kedua bahasa).
9	Semangkok bakso dengan toge	(1) lapek (kue Minang); (2) kue 8 jam Palembang; (3) lontong	Tidak (rank 676)	GAGAL berat; rank terburuk. EN: rank 3.
10	Binatang khas penghuni Gunung Sindoro, yaitu babi hutan / celeng.	(1) gambar pasangan (skor 0,321); (2) tradisi pare gede; (3) komodo	Ya (rank 1)	Satu-satunya yang berhasil. EN: rank 1.

Hanya satu dari sepuluh query yang berhasil di rank 1. Ukuran galeri (2.072) dan target satu-satu membuat R@1 ketat; pada contoh 5, 6, dan 7 top-3 sebenarnya bertema benar (kota, penari, becak). Dua kegagalan yang paling informatif:

Contoh 9, "Semangkok bakso dengan toge" (rank 676). Gambarnya semangkuk bakso berkuah dengan kantong plastik berisi mi dan tauge di depannya. Dengan caption Inggris pasangannya, gambar yang sama berada di rank 3, jadi gambar dapat dikenali dan kegagalannya berasal dari sisi teks Indonesia. Jenis kegagalannya adalah kata: "bakso" dan "toge" adalah istilah makanan lokal dalam kalimat pendek, dan top-3 berisi kue dan lontong. Kekacauan visual (plastik menutupi sebagian mangkuk) kemungkinan ikut berperan; kami belum mengujinya.

Contoh 2, "Kerupuk rasa durian" (rank 13). Ketiga hasil teratas adalah foto buah durian, padahal gambar pasangannya adalah kemasan kerupuk berlabel "Kerupuk Rasa Durian". Jenis kegagalannya adalah relasi: encoder mengambil kata benda yang paling menonjol ("durian") dan kehilangan hubungan "kerupuk dengan rasa durian". Caption Inggris pasangannya ("Durian flavored crackers") menempatkan gambar yang sama di rank 1, jadi sumber masalahnya bahasa, bukan gambar.

6 Reproduksi

```
pip install numpy torch transformers sentence-transformers pillow pandas
python m1_baseline.py --seed 0
```

Perangkat: Intel Core i5-12500H (12 inti, 16 thread), RAM 15,6 GB, tanpa GPU (`--device cpu`), Windows 11, Python 3.14.0, torch 2.9.1+cpu, transformers 5.17.0, sentence-transformers 6.3.0. Waktu jalan dari cache sematan kosong (model sudah terunduh): 236,6 detik, dengan rincian gambar train 140 s, gambar val 17 s, caption Indonesia 28 s + 4 s, caption Inggris 32 s + 4 s, dan pemuatan model 12 s. Pengunduhan model pertama kali (sekitar 1,1 GB) menambah beberapa menit. Menjalankan ulang dengan `--no-cache` memberi angka yang identik.

Hasil mentah ada di `hasil_m1/`: `results_val.csv/json`, `rank_per_item_val.csv`, `contoh_query_id.csv`, `audit_data.json`, `analisis_val.json` (dari `python m1_analisis.py`), dan `cache/emb_{train,val}.npz`.

> **Atribusi data**
> Data: SEA-VL Indonesian subset (`KORIKA-AI/sea-vl_crowdsourcing_id`), diturunkan dari SEACrowd/sea-vl_crowdsourcing, lisensi **CC BY-SA 4.0** (creativecommons.org/licenses/by-sa/4.0). Sitasi: Cahyawijaya et al. (2025), Crowdsource, Crawl, or Generate? Creating SEA-VL, a Multicultural Vision-Language Dataset for Southeast Asia, ACL.