KELOMPOK [[NN]] · PROPOSAL M0

Proposal proyek akhir

Cross-modal retrieval pada data budaya Indonesia

KELOMPOK	[[05]] · [[FARID 16 PM]]	MATA KULIAH	IF25-40304 · Ganjil 2026/2027
DOSEN PENGAMPU	I Wayan Wiprayoga Wisesa	TAHAP	M0 · Pertemuan 10

1 Rumusan masalah

Mengevaluasi dan meningkatkan performa sistem *cross-modal retrieval* berbasis *dual-encoder* pada dataset budaya Indonesia (SEA-VL) dengan mempersempit kesenjangan performa bahasa (*language gap*) antara query berbahasa Indonesia dan Inggris tanpa mengubah bobot representasi beku.

2 Hipotesis

Penerapan prompt ensemble berbasis templat dan deskripsi budaya Indonesia akan menaikkan metrik Recall@1 pada query teks-ke-gambar bahasa Indonesia, karena variasi konteks templat mampu menangkap sinonimitas dan ragam sintaksis lokal yang tidak dapat diwakili oleh teks tunggal secara representatif.

3 Metrik

Evaluasi dilakukan pada split validasi menggunakan metrik standar perangkingan:

- **Recall@1, Recall@5, Recall@10:** Mengukur proporsi kemunculan item relevan (*ground truth*) pada top-K kandidat hasil pencarian.
- **mAP@K (mean Average Precision @ K):** Mengukur ketepatan urutan peringkat relevansi pada top-K kandidat.

Metrik dihitung untuk 4 arah pencarian lintas modal:

1. Gambar $\rightarrow$ Teks Indonesia
2. Gambar $\rightarrow$ Teks Inggris
3. Teks Indonesia $\rightarrow$ Gambar
4. Teks Inggris $\rightarrow$ Gambar

4 Rencana pendekatan utama

Tandai satu pendekatan utama (boleh dikombinasikan; boleh berubah setelah M1).

☐ (a) mengganti encoder multibahasa (misalnya model berbasis SigLIP atau multilingual CLIP yang lebih baru)

✅ (b) prompt ensemble berbahasa Indonesia, termasuk terjemahan dan variasi templat

☐ (c) melatih proyeksi/adapter kecil di atas representasi beku

☐ (d) reranking dengan cross-encoder pada sejumlah kandidat teratas

☐ (e) augmentasi data dengan terjemahan

Kelompok memilih pendekatan **(b)** karena tidak memerlukan komputasi pelatihan tambahan sehingga sangat efisien di CPU, sekaligus menyasar langsung akar masalah representasi leksikal bahasa Indonesia pada ruang laten teks. Pada tahap M2, kami akan membandingkan sekurang-kurangnya dua varian *prompt ensemble* terhadap baseline M1:

- **Varian 1 (Handcrafted Cultural Templates):** Menggunakan kumpulan templat spesifik konteks budaya Indonesia (misal: *"sebuah foto dari {caption}"*, *"dokumentasi budaya Indonesia berupa {caption}"*, *"potret tradisi {caption}"*).
- **Varian 2 (Multi-Templat + Terjemahan Balik / Pseudo-Caption):** Menggabungkan templat struktural dengan ekspansi sinonim dan variasi kalimat deskriptif untuk merata-ratakan vektor teks (*embedding averaging*) sebelum perhitungan kesamaan kosinus.

5 Pembagian kerja

#	Peran	Nama	Target sampai M2
1	Data dan Etika Data	Muhamad Rafi Ilham	Memeriksa duplikat & sebaran kategori bundel SEA-VL, mengaudit potensi *data leakage* pada perancangan varian prompt, serta menyusun draf analisis etika keterwakilan budaya.
2	Baseline dan Pipeline	Cikal Galih Nur Arifin	Menjalankan reproduksi baseline M0, membangun skrip pencarian *end-to-end* 4 arah pada M1, dan mengintegrasikan modul inferensi *multi-prompt ensemble* untuk pengujian M2.
3	Eksperimen Penyejajaran/Fusi	Raditya Alrasyid Nugroho	Merancang matriks varian prompt templat budaya Indonesia, mengeksekusi *ablation study* (pengaruh jumlah templat terhadap akurasi), serta mencatat waktu komputasi.

#	Peran	Nama	Target sampai M2
4	Evaluasi dan Uji Kasus Sulit	Jana Rohman Wasiso	Mengimplementasikan perhitungan metrik Recall@K dan mAP@K, menyusun tabel komparasi M1 vs varian M2, serta mengidentifikasi sampel kesalahan (contoh gagal).
5	Integrasi dan Koordinasi	Muhammad Fatahillah Farid	Menyusun dokumen Proposal M0, mengompilasi laporan mingguan M1 dan M2, mengelola logbook kontribusi, serta memastikan kepatuhan jadwal pengumpulan dan atribusi CC BY-SA 4.0.

6 Reproduksi baseline

Jalankan kembali perhitungan *baseline* dari lembar kerja Pertemuan 09 dan tulis angka Anda sendiri.

Besaran	Angka hasil reproduksi	Seed	Perangkat dan waktu jalan
InfoNCE (τ = 0,10)	10,6138 (sebelum penyelarasan) → 0,1618 (sesudah Procrustes)	42	Intel Core i3-1115G4 @ 3,00 GHz, RAM 8 GB, Windows 11 Home Single Language, tanpa GPU; waktu eksekusi skrip total 1,80 detik (Python 3.13.3, numpy 2.5.4)
Recall@1	1/6 (sebelum) → 6/6 (sesudah). Pembanding acak: 1/6 ≈ 0,1667	42	Intel Core i3-1115G4 @ 3,00 GHz, RAM 8 GB, Windows 11 Home Single Language, tanpa GPU; waktu eksekusi skrip total 1,80 detik (Python 3.13.3, numpy 2.5.4)

Baris yang diminta: *InfoNCE* dan *Recall@1*. Pembanding acak untuk N gambar validasi: *Recall@1* = 1/N.

Angka hasil reproduksi kami selaras dengan lembar kerja Pertemuan 09 sampai empat desimal: InfoNCE 10,6138 → 0,1618, Recall@1 1/6 → 6/6, dan untuk τ = 0,05/0,10/0,50 diperoleh 0,1013/0,1618/0,6265. Karena tidak ada selisih, tidak ada yang perlu dijelaskan; eksekusi memakai default_rng(42), Python 3.13.3, dan numpy 2.5.4 di CPU. Pembanding acak untuk lembar kerja ini adalah 1/6 ≈ 0,1667 (N = 6 pasangan sintetis), sehingga Recall@1 sebelum penyelarasan (1/6) setara tebakan acak.

7 Pemeriksaan awal bundel

Pemeriksaan awal dataset menunjukkan terdapat 2.072 data train dan 275 data validation dengan total 2.347 gambar. Distribusi kategori belum seimbang, dengan kategori kuliner paling dominan (792 train dan 106 validation), sedangkan kategori alat musik hanya memiliki 4 data train dan tidak memiliki data validation.

Tidak ditemukan duplikat image_id, duplikat path gambar antar-split, maupun file gambar identik berdasarkan SHA-256. Seluruh referensi file gambar juga ditemukan. Namun, terdapat 12 baris validation dengan minimal satu caption identik terhadap data train, yaitu 11 kecocokan caption Indonesia dan 11 kecocokan caption Inggris. Temuan ini perlu diperhatikan pada evaluasi berikutnya karena berpotensi mempengaruhi independensi data, meskipun belum membuktikan adanya duplikasi gambar atau data leakage.

8 Pernyataan integritas

Pernyataan integritas ditandatangani seluruh anggota dan dilampirkan bersama berkas ini (formulir LMS, atau `pernyataan-integritas.docx`).

✅ Formulir terlampir dan ditandatangani lima anggota.

✅ Nama kelompok dan pembagian peran sudah final (dikunci pada M0).

Atribusi data

Data: SEA-VL Indonesian subset (`KORIKA-AI/sea-vl_crowdsourcing_id`), diturunkan dari SEACrowd/sea-vl*crowdsourcing, lisensi **CC BY-SA 4.0** (creativecommons.org/licenses/by-sa/4.0). Sitasi: Cahyawijaya et al. (2025),* Crowdsource, Crawl, or Generate? Creating SEA-VL, a Multicultural Vision-Language Dataset for Southeast Asia_, ACL.